

پاسخ تمرین دوم هوش مصنوعی

سوال (۱)

الف. در الگوریتم Simulated Annealing اگر دما به اندازه کافی کند کاهش نیابد، شانس پیدا کردن بهینه سراسری کم می‌شود.
ب. در این حالت، احتمال رفتن به یک همسایه بدتر تنها به ΔE بستگی دارد. همچنین چون دما با گذر زمان کاهش نمی‌یابد، احتمال خروج از یک نقطه بهینه نیز کاهش نیافته و شانس رسیدن به بهینه سراسری کمتر است.
ج. با فرض آنکه شرط پایان الگوریتم $T = 0$ نباشد، احتمال رفتن به یک همسایه بدتر صفر خواهد بود. به این ترتیب الگوریتم در هر حالت، همسایه‌ها را با ترتیب تصادفی انتخاب می‌کند تا جایی که به اولین همسایه بهتر برسد. پس الگوریتم مانند First Choice Hill-climbing عمل می‌کند.

سوال (۲)

سوال (۲)

آ) فضای جستجو برابر است با:

$$2^n$$

ب) n همسایه

ج) بیشینه کردن تعداد عبارات disjunction که true می‌شوند. (که این مقدار برابر تعداد اعضای conjunction است)
د) در این حالت تعداد عبارات disjunction که true می‌شوند برابر است با 3. با تغییر هریک از متغیرها این تعداد به صورت زیر تغییر می‌کند که الگوریتم بهترین آن‌ها را انتخاب می‌کند.

A -> 4 تغییر

B -> 4 تغییر

C -> 3 تغییر

D -> 4 تغییر

بنابراین یکی از تغییرات A، B، یا D به صورت رندوم انتخاب می‌شود.

ه) مقداری A(true)، B(false)، C(true) یک بهینه محلی تولید می‌کند چرا که در این حالت تعداد عبارات true برابر 3 است و در همه حالات همسایه هم این تعداد برابر 3 است.

Date.

3- اے حسن کاف اے اے حسن اے ہم ہمارے عزیز ہیں۔ یہ کہتے ہیں کہ یہاں ہمارے دوست ہیں۔

و کای در این شهر ره را کی نه بی خواهم در این شهرت با راهی نویسم. اما هیچ Pitchess برای

اینجی مدخل تعداد اعداد صحیح در این دسته است هر کدام بر این

تعداد کل افسر و ملازمین در مجموع ۴۰ نفر تقسیم بر دو اصل اعتبار انتخاب دارند.

تمام cross-over به این صورت است که در نمودار از یک قسمت به طرف دیگر

دوبہ صورت دودہ نام ترکیب ہی کہیں برائے اخلاقیہ میں ترکیبی از حدیث و حدیث انتہائی

سردہ دوم اس سرائے اصلی بہ جاس عدد فعلی، عدد آن بھی سرائے میں ملے گا۔

چون از برای یک رأس در این رشته قرار دهم پس در رشته همواره در حال Verden over

کرا دارد

مدلسازی مسئله با گرفتن رشته‌ای دودویی به طول $|V|$ برای نشان دادن حضور یا عدم حضور هر راس نیز صحیح است. اما لطفاً به منفی نشدن تابع Fitness و همچنین درستی آن در مقایسه رشته‌ها دقت کنید. شرط پوشاندن تمام یال‌های گراف، یک شرط ضروری است و پاسخ باید این ویژگی را داشته باشد. به عنوان مثال اگر بین دو راس a و b با درجه یک، دقیقاً یال باشد، تابع Fitness شما نباید برنداشتن دو راس a و b را ترجیح دهد.

سوال (۴)

سوال ۴: به هر زیر مجموعه یک رشته باینری n حرف n (۰: اشاره به صفر، ۱: اشاره به یک) متناظر می‌کنیم. عضو نام در زیر مجموعه وجود دارد اگر و تنها اگر کلاسه نام رشته ۱ باشد.

حسابی هر رشته را رشته‌هایی در نظر می‌گیریم که با حذف اعضاء کردن یک عضو (طوری که هنوز هنوز) به وجود می‌آیند. یعنی یک بیت را انتخاب کرده و آن را ناک کنیم. تعداد حسابی‌ها برای مجموعه‌های یک عضو $n-1$ تا n (چون نمی‌توانیم یک عضو را حذف کنیم) و برای مابقی n تا n (تعداد حالت‌های انتخاب یک بیت) است.

تابع هدف را می‌توانیم به صورت $f(x)$ تعریف کنیم و هدفمان مینیمم کردن این تابع است.

ب) زیر مجموعه $\{1, 2, 3, 4\}$ یک بهینه محلی است چون با اضافه کردن هر کدام از ۵ و ۶ یا حذف هر کدام از اعضاء دیگر اعضاء از ۱ بهتر می‌شود. در بهینه کلان هم $\{1, 2, 3, 4\}$ است.

این بهینه‌های پیدا کردن حسابی‌ها در حالت حرکت جابجا کردن یک عضو بدون مجموعه با یک عضو بیرون مجموعه (جایگزینی یک صفر و یک یک در صورت وجود) را هم اضافه کنیم در مثال داده شد. بهینه محلی نداشتیم.

حالت اما مثلاً در $\{1, 2, 3, 4, 5, 6\}$ زیر مجموعه $\{1, 2, 3, 4, 5, 6\}$ بهینه محلی می‌شود.

سوال ۵

الف) نادرست! فرض کنید $f(x) = x^2$ است و در حالت اولیه از $x^{(0)} = 1$ شروع کرده باشیم و $\epsilon = 1$ در اینصورت $x^{(2i)} = 1$, $x^{(2i+1)} = -1$ و همیشه بین دو مقدار -1 و 1 این مقدار جابه‌جا می‌شود و در نتیجه هیچ‌گاه همگرا نخواهد شد.

ب) درست! اگر در مرحله‌ای به کمینه محلی برسیم مشتق مورد نظر در آن نقطه صفر می‌شود و عبارت:

$$x^{(t)} = x^{(t-1)} - \epsilon f'(x^{(t-1)}) = x^{t-1}$$

پس در نتیجه همیشه در این نقطه که نقطه x^* نیست می‌مانیم.

ج) نادرست! مثال نقض چنین چیزی تابعی مثل

$$f(x) = \frac{1}{4}x^4 + \frac{1}{3}x^3 - x$$


است. این تابع محدب نیست! برای بررسی این موضوع کافیست دو بار مشتق بگیریم:

$$f'(x) = x^3 + x^2 - 1$$

$$f''(x) = 3x^2 + 2x$$

در نقطه -0.5 این مقدار منفی است!

مثال:



نکته: یک نقطه از این تابع صفر است و در صورت همگرا
 به آن می‌رسیم که همان مینیمم مطلق است.
 اما تابع محدب نیست.

د) درست! ابتدا ثابت می‌کنیم اگر تابع f محدب باشد و الگوریتم همگرا شود به x^* همگرا می‌شود. در صورت محدب بودن می‌دانیم f' یک تابع صعودی است چون در x^* مینیمم است می‌دانیم تا قبل از x^* مقدار f' منفی است و پس از آن مثبت است. بنابراین اگر $x^{(t)}$ پس از x^* باشد کم می‌شود و اگر قبل از x^* باشد زیاد می‌شود. بنابراین در صورت همگرایی یکسری کم و زیاد شدن داریم و می‌دانیم x^* در بین این کم و زیاد شدن هاست پس همیشه فاصله $x^{(t)}$ از x^* یعنی $|x^{(t)} - x^*|$ در حال کم شدن است. لذا به همین مقدار همگرا می‌شود.

حالا کافیت بگوییم این تابع محدب است تا ثابت شود به x^* همگرا شود. برای اینکار ثابت می‌کنیم مشتق دوم مثبت است:

$$f(x) = (y - wx)^2 \rightarrow f'(x) = 2(y - wx)(-w) = w^2x - 2yw \rightarrow f''(x) = w^2 > 0$$

سوال ۶)

(آ)

$$\nabla f(x_1, x_2, x_3, x_4) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \frac{\partial f}{\partial x_3}, \frac{\partial f}{\partial x_4} \right)$$

$$\frac{\partial f}{\partial x_1} = 2 \times 1 \times (x_1 + 10x_2) + 3x_4^2$$

$$\frac{\partial f}{\partial x_2} = 2 \times 10 \times (x_1 + 10x_2) + 5 \times 3 \times x_2^2 + 4 \times 1 \times (x_2 - 2x_3)^3$$

$$\frac{\partial f}{\partial x_3} = 4 \times (x_2 - 2x_3)^3 \times (-2)$$

$$\frac{\partial f}{\partial x_4} = 2 \times 3x_1x_4$$

$$\nabla f(x_1, x_2, x_3, x_4) =$$

$$(2x_1 + 20x_2 + 3x_4^2, 20(x_1 + 10x_2) + 15x_2^2 + 4(x_2 - 2x_3)^3, -8(x_2 - 2x_3)^3, 6x_1x_4)$$

بنابراین داریم:

$$(10, 5, 5, 4) - 0.1 \times \nabla f(10, 5, 5, 4) = (-6.8, -102.5, -95, -20)$$

$$(-6.8, -102.5, -95, -20) - 0.1 \times \nabla f(-6.8, -102.5, -95, -20)$$

$$= (79.56, -281767.025, 535842.5, -101.6)$$

برای قسمت ب، به ازای learning rate بزرگ ممکن است الگوریتم همگرا نشود یا واگرا شود. به ازای learning rate بسیار کوچک هم زمان زیادی طول می کشد تا الگوریتم همگرا شود. راهکارهای متفاوتی برای تعیین learning rate را میتوانید در لینک زیر مشاهده کنید:

<https://automaticaddison.com/how-to-choose-an-optimal-learning-rate-for-gradient-descent/>

اگر جواب دیگری نوشتید که منطقی و درست است نمره سوال را می گیرید. توجه کنید که فرق قسمت ب با ج در این سوال در این بود که در قسمت ب امکان محاسبه دقیق گرادیان به صورت ریاضی وجود داشت و میشد با بررسی گرادیان تابع loss و تغییرات آن بر حسب متغیرها مقدار مناسبی برای learning rate محاسبه کرد.

ج) در توابع غیرمحدب (non-convex) نمی‌توان مطمئن شد که به نقطه‌ی کمینه‌ی سراسری رسیده‌ایم یا خیر. زیرا علاوه‌بر عوامل دیگر بسیار بستگی به نقطه‌ی شروع دارد.

در توابع محدب (convex) با انتخاب مقدار مناسب (نه لزوماً کوچک‌ترین مقدار) برای Learning Rate می‌توان مطمئن شد که الگوریتم نقطه‌ی کمینه‌ی سراسری را پیدا می‌کند. به طور دقیق‌تر، اگر اندازه‌ی گام‌ها بسیار بزرگ نباشد، تابع به یک مقدار با کمی خطا هم‌گرا می‌شود و چون تابع محدب است، کمینه‌ی سراسری خواهد بود. یعنی مقدار گرادیان در آن نقطه بسیار نزدیک به صفر خواهد بود. به طور کلی می‌توان رفته رفته مقدار Learning Rate را کاهش داد تا به نقطه‌ی مناسب با خطای کم‌تر رسید.

سوال ۷. باید ثابت کنیم: $\forall x, y \in \mathbb{R}, 0 \leq \alpha \leq 1: (f+g)(\alpha x + (1-\alpha)y) \leq \alpha(f+g)(x) + (1-\alpha)(f+g)(y)$.
 f, g محدب اند. داریم: $(f+g)(\alpha x + (1-\alpha)y) = f(\alpha x + (1-\alpha)y) + g(\alpha x + (1-\alpha)y)$
 $\leq \alpha f(x) + (1-\alpha)f(y) + \alpha g(x) + (1-\alpha)g(y) = \alpha(f(x) + g(x)) + (1-\alpha)(f(y) + g(y))$
 در قسمت (آ) حکم ثابت شد \rightarrow
 (ب) قدری دهیم $h = \max\{f, g\}$ و حال باید ثابت کنیم:

$\forall x, y \in \mathbb{R}, 0 \leq \alpha \leq 1: h(\alpha x + (1-\alpha)y) \leq \alpha h(x) + (1-\alpha)h(y)$
 اما توجه کنید به ازای هر $x \in \mathbb{R}$ داریم: $h(x) \geq f(x)$ و $h(x) \geq g(x)$ و از آنجایی که $h(x) = f(x)$ یا $h(x) = g(x)$ لذا حکم معادل اثبات این دو حکم است:
 $f(\alpha x + (1-\alpha)y) \leq \alpha h(x) + (1-\alpha)h(y)$ (۱)
 $g(\alpha x + (1-\alpha)y) \leq \alpha h(x) + (1-\alpha)h(y)$ (۲)
 از آنجایی که f, g محدب اند داریم: $f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) \leq \alpha h(x) + (1-\alpha)h(y)$
 $g(\alpha x + (1-\alpha)y) \leq \alpha g(x) + (1-\alpha)g(y) \leq \alpha h(x) + (1-\alpha)h(y)$
 و این گونه ثابت می شود که $\max\{f(x), g(x)\} \leq \alpha h(x) + (1-\alpha)h(y)$ نیز در صورت محدب بودن f و g محدب اند.

ج. f and g are positive and convex, hence for $0 \leq \theta \leq 1$,

$$\begin{aligned} f(\theta x + (1-\theta)y) g(\theta x + (1-\theta)y) &\leq (\theta f(x) + (1-\theta)f(y)) (\theta g(x) + (1-\theta)g(y)) \\ &= \theta f(x)g(x) + (1-\theta)f(y)g(y) \\ &\quad + \theta(1-\theta)(f(y) - f(x))(g(x) - g(y)). \end{aligned}$$

The third term is less than or equal to zero if f and g are both increasing or both decreasing. Therefore

$$f(\theta x + (1-\theta)y) g(\theta x + (1-\theta)y) \leq \theta f(x)g(x) + (1-\theta)f(y)g(y).$$

د. تابع $g(x)$ نزولی و مقعر است. بنابراین تابع $\frac{1}{g(x)}$ صعودی و محدب خواهد بود. با استفاده از قسمت ج، این قسمت ثابت می شود.